



北京航空航天大学  
BEIHANG UNIVERSITY

# 数值分析

主讲教师：贺慧霞

北京航空航天大学数学科学学院



# 第三章 矩阵特征值与特征向量的算法



# 一、特征值问题及其性质

**定义 1** 已知  $A = (a_{ij})_{n \times n}$ , 则称

$$\phi(\lambda) = \det(\lambda I - A) = \begin{vmatrix} \lambda - a_{11} & -a_{12} & \cdots & -a_{1n} \\ -a_{21} & \lambda - a_{22} & \cdots & -a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ -a_{n1} & -a_{n2} & \cdots & \lambda - a_{nn} \end{vmatrix}$$

$$= \lambda^n - (a_{11} + a_{22} + \cdots + a_{nn})\lambda^{n-1} + \cdots + (-1)^n |A|$$

为  $A$  的**特征多项式**.



**定义2** 特征多项式  $\phi(\lambda) = \det(\lambda I - A) = 0$  的根称为  $A$  的**特征值**， $\lambda(A)$  表示  $A$  的所有特征值的集合。

设  $\lambda$  为  $A$  的特征值, 相应的齐次方程组  $(\lambda I - A)x = 0$  的非零解  $x$  称为  $A$  的对应于  $\lambda$  的**特征向量**。

**定理1** 设  $\lambda$  是矩阵  $A \in R^{n \times n}$  的特征值， $x$  是对应的非零特征向量，则

- (1)  $c\lambda$  是  $cA$  的特征值 (常数  $c \neq 0$ );
- (2)  $\lambda - p$  为  $A - pI$  的特征值, 即  $(A - pI)x = (\lambda - p)x$ ;
- (3)  $\lambda^k$  是  $A^k$  的特征值, 即  $A^k x = \lambda^k x$ ;
- (4) 设  $A$  非奇异, 则  $\lambda \neq 0$  且  $\frac{1}{\lambda}$  为  $A^{-1}$  的特征值, 即  $A^{-1}x = \frac{1}{\lambda}x$ .



**定理2** 若 $\lambda_i (i = 1, \dots, n)$ 是矩阵 $A$ 的特征值, 则

$$(1) \sum_{i=1}^n \lambda_i = \sum_{i=1}^n a_{ii} = \text{tr}(A), \quad (2) \det(A) = \lambda_1 \cdots \lambda_n.$$

**定理3** 设 $A \in R^{n \times n}$ , 则  $\lambda(A^T) = \lambda(A)$ .

**定理2** (1) 设矩阵 $A \in R^{n \times n}$ 可对角化, 即存在非奇异矩阵 $P$ 使

$$P^{-1}AP = \begin{bmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_n \end{bmatrix},$$

的充分必要条件是 $A$ 具有 $n$ 个线性无关的特征向量.



(2) 如果矩阵  $A \in R^{n \times n}$  有  $m$  个 ( $m \leq n$ ) 不同的特征值  $\lambda_1, \lambda_2, \dots, \lambda_m$ , 则对应的特征向量  $x_1, x_2, \dots, x_m$  线性无关.

**定义** 设  $A \in R^{n \times n}$  为对称矩阵, 对于任一非零向量  $x \neq 0$ , 称

$$R(x) = \frac{(Ax, x)}{(x, x)},$$

为对应于向量  $x$  的**瑞利(Rayleigh)商**.



**定理4** 设 $A$ 为分块上三角阵,

$$A = \begin{bmatrix} A_{11} & A_{12} & \cdots & A_{1m} \\ & A_{22} & \cdots & A_{2m} \\ & & \ddots & \vdots \\ & & & A_{mm} \end{bmatrix}$$

其中每个对角块  $A_{ii}$  均为方阵, 则  $\lambda(A) = \bigcup_{i=1}^m \lambda(A_{ii})$ .

**定理5** 若 $A$ 与 $B$ 为相似矩阵, 即 $\exists$ 非奇异 $P$ 使 $P^{-1}AP = B$ , 则

- (1)  $A$ 与 $B$ 有相同的特征值;
- (2) 若 $y$ 是 $B$ 的特征向量, 则 $Py$ 是 $A$ 的特征向量.



**定理 6(对称矩阵的正交约化 )** 设  $A \in R^{n \times n}$  为对称矩阵 , 则

- (1)  $A$  的特征值均为实数;**
- (2)  $A$  有  $n$  个线性无关的特征向量 ;**
- (3) 存在正交矩阵  $P$  使得**

$$P^{-1}AP = \begin{bmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_n \end{bmatrix},$$

且  $\lambda_i (i = 1, 2, \dots, n)$  为  $A$  的特征值, 而  $P = (u_1, u_2, \dots, u_n)$  的列向量  $u_j$  为对应于  $\lambda_j$  的特征向量.





**定理7** 设  $A \in R^{n \times n}$  为对称矩阵(其特征值依次记为  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$ ), 则

$$(1). \quad \lambda_n \leq \frac{(Ax, x)}{(x, x)} \leq \lambda_1 \quad (\text{对任何非零 } x \in R^n);$$

$$(2). \quad \lambda_1 = \max_{\substack{x \in R^n \\ x \neq 0}} \frac{(Ax, x)}{(x, x)} \quad \lambda_n = \min_{\substack{x \in R^n \\ x \neq 0}} \frac{(Ax, x)}{(x, x)} \quad (1.3)$$



**证明** 只证(1), 关于(2)自己作练习.

由于 $A$ 为实对称矩阵, 可将 $\lambda_1, \lambda_2, \dots, \lambda_n$ 对应的特征向量 $x_1, x_2, \dots, x_n$ 正交规范化, 则有 $(x_i, x_j) = \delta_{ij}$ , 设 $x \neq 0$ 为 $R^n$ 中任一向量, 则有

$$x = \sum_{i=1}^n \alpha_i x_i, \quad \|x\|_2 = \sqrt{\sum_{i=1}^n \alpha_i^2} \neq 0.$$

于是

$$\lambda_n \leq \frac{(Ax, x)}{(x, x)} = \frac{\sum_{i=1}^n \alpha_i^2 \lambda_i}{\sum_{i=1}^n \alpha_i^2} \leq \lambda_1.$$

从而(1)成立. 结论(1)说明**瑞利商**必位于 $\lambda_n$ 和 $\lambda_1$ 之间.



# 特征值的应用背景

- ❖ 求系统的固有振动频率
- ❖ 求机械系统的振动频谱（模态）
- ❖ 系统的稳定性分析
- ❖ 物理学中的某些临界值的确定



# 常用的数值求特征值的方法

## ➤ 幂法与反幂法

幂法是一种求实矩阵 $A$ 的按模最大的特征值 $\lambda_1$ 及其对应的特征向量 $x_1$ 的方法。特别适合于大型稀疏矩阵。

## ➤ Jacobi法

Jacobi是一种求实对称矩阵 $A$ 的全部特征值及其对应的特征向量的方法。特别适合于中小型对称矩阵。

## ➤ QR分解法

QR方法是一种变换方法，是计算一般(中小型)矩阵全部特征值问题的最有效方法之一。

## ➤ .....



## 3.1 幂法与反幂法

**幂法**是一种计算矩阵**主特征值**(矩阵按模最大的特征值)及对应特征向量的迭代方法.



## 二、幂法

### 1、主特征值是单根.

**问题 1:** 假设实矩阵  $A$  具有  $n$  个线性无关的特征向量  $x_1, x_2, \dots, x_n$ ; 相应的特征值  $\lambda_1, \lambda_2, \dots, \lambda_n$ , 已知矩阵的**主特征值**  $\lambda_1$  为实数, 且满足

$$|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_n|,$$

讨论求  $\lambda_1$  及其对应特征向量的方法.

则任意非零向量  $v$  可表示为  $v = \alpha_1 x_1 + \alpha_2 x_2 + \dots + \alpha_n x_n$ ,

取非零向量  $v_0$ :  $v_0 = \alpha_1 x_1 + \alpha_2 x_2 + \dots + \alpha_n x_n$ ,

假设  $\alpha_1 \neq 0$ .



## 幂法的基本思想是:

任取**非零**的初始向量 $\mathbf{v}_0$ ，由矩阵 $A$ 构造一向量序列 $\{\mathbf{v}_k\}$

$$\begin{cases} \mathbf{v}_1 = A\mathbf{v}_0, \\ \mathbf{v}_2 = A\mathbf{v}_1 = A^2\mathbf{v}_0, \\ \dots\dots\dots \\ \mathbf{v}_{k+1} = A\mathbf{v}_k = A^{k+1}\mathbf{v}_0, \\ \dots\dots\dots \end{cases} \quad (2.1)$$

称为**迭代向量**，由假设， $\mathbf{v}_0$ 可唯一表示为

$$\mathbf{v}_0 = \alpha_1 \mathbf{x}_1 + \alpha_2 \mathbf{x}_2 + \cdots + \alpha_n \mathbf{x}_n \quad (\text{设 } \alpha_1 \neq 0), \quad (2.2)$$



**定义：** 由已知非零向量  $v_0$  及矩阵  $A$  的乘幂  $A^k$  构造向量序列  $\{v_k\}$  以计算矩阵  $A$  的**主特征值及相应**特征向量的方法称为**幂法**。

$$v_0 = \alpha_1 x_1 + \alpha_2 x_2 + \cdots + \alpha_n x_n \quad (\text{设 } \alpha_1 \neq 0), \quad (2.2)$$

$$v_k = A v_{k-1} = A^2 v_{k-2} = \cdots = A^k v_0 = \alpha_1 A^k x_1 + \alpha_2 A^k x_2 + \cdots + \alpha_n A^k x_n$$

$$= \alpha_1 \lambda_1^k x_1 + \alpha_2 \lambda_2^k x_2 + \cdots + \alpha_n \lambda_n^k x_n$$

$$= \lambda_1^k \left[ \alpha_1 x_1 + \alpha_2 \left( \frac{\lambda_2^k}{\lambda_1^k} \right) x_2 + \cdots + \alpha_n \left( \frac{\lambda_n^k}{\lambda_1^k} \right) x_n \right] \quad \varepsilon_k \xrightarrow{k \rightarrow \infty} 0$$

当  $\alpha_1 \neq 0$  时,  $v_k \approx \lambda_1^k \alpha_1 x_1$ ,  $\cancel{A v_k} = v_{k+1} \approx \lambda_1^{k+1} \alpha_1 x_1 = \lambda_1 v_k$

即  $v_k$  可以近似的作为**属于  $\lambda_1$  的特征向量**。

$$v_k = \lambda_1^k [\alpha_1 x_1 + \varepsilon_k]$$





$$\boldsymbol{v}_k = \lambda_1^k [\alpha_1 \boldsymbol{x}_1 + \boldsymbol{\varepsilon}_k]$$

用  $(\boldsymbol{v}_k)_i$  表示  $\boldsymbol{v}_k$  的第  $i$  个分量, 则当  $k$  充分大时, 有

$$\frac{(\boldsymbol{v}_{k+1})_i}{(\boldsymbol{v}_k)_i} = \frac{\lambda_1^{k+1} [\alpha_1 (\vec{x}_1)_i + (\vec{\varepsilon}_{k+1})_i]}{\lambda_1^k [\alpha_1 (\vec{x}_1)_i + (\vec{\varepsilon}_k)_i]} = \lambda_1 \left\{ \frac{\alpha_1 (\vec{x}_1)_i + (\vec{\varepsilon}_{k+1})_i}{\alpha_1 (\vec{x}_1)_i + (\vec{\varepsilon}_k)_i} \right\} \xrightarrow{k \rightarrow \infty} \lambda_1$$

即为  $A$  的主特征值  $\lambda_1$  的近似值.

**此时**两相邻迭代向量的对应非零分量的比值一定收敛到主特征值!

**定理 1:** 1. 假设实矩阵  $A$  具有  $n$  个线性无关的特征向量  $\boldsymbol{x}_1, \boldsymbol{x}_2, \dots, \boldsymbol{x}_n$ ;  
2. 相应的特征值  $\lambda_1, \lambda_2, \dots, \lambda_n$  满足  $|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_n|$ , 于是  
对任何非零初始向量  $\boldsymbol{v}_0$ ,

$$\lambda_1 \approx \frac{(\boldsymbol{v}_{k+1})_i}{(\boldsymbol{v}_k)_i}, \quad \text{及 } \boldsymbol{x}_1 \approx \boldsymbol{v}_k.$$



迭代公式实质上是由矩阵 $A$ 的乘幂 $A^k$ 与非零向量 $\mathbf{v}_0$ 相乘来构造向量序列 $\{\mathbf{v}_k\}=\{A^k\mathbf{v}_0\}$ ，从而计算主特征值 $\lambda_1$ 及其对应的特征向量，这就是幂法的思想。

$$\frac{(\mathbf{v}_{k+1})_i}{(\mathbf{v}_k)_i} \rightarrow \lambda_1 \quad (k \rightarrow \infty).$$

的收敛速度由比值

$$r = \left| \frac{\lambda_2}{\lambda_1} \right|,$$

来确定， $r$  越小收敛越快，但当 $r \approx 1$ 时收敛可能很慢。



## 2、主特征值是重根.

**问题2:** 假设实矩阵 $A$ 具有 $n$ 个线性无关的特征向量 $x_1, x_2, \dots, x_n$ ; 相应的特征值 $\lambda_1, \lambda_2, \dots, \lambda_n$ , 已知矩阵的**主特征值** $\lambda_1$ 为实数, 且满足

$$|\lambda_1| = |\lambda_2| = \dots = |\lambda_r| > |\lambda_{r+1}| \geq \dots \geq |\lambda_n|,$$

**讨论求 $\lambda_1$ 及其对应特征向量的方法.**

$\forall \vec{u}_0 \neq \vec{0}, \vec{u}_0 = \alpha_1 x_1 + \alpha_2 x_2 + \dots + \alpha_n x_n$ , 假设 $\alpha_1, \dots, \alpha_r$ 不全为零.

$$u_k = A^k u_0 = \lambda_1^k \left[ \sum_{i=1}^r \alpha_i x_i + \sum_{j=r+1}^n \alpha_j \left( \frac{\lambda_j^k}{\lambda_1^k} \right) x_j \right] = \lambda_1^k \left[ \sum_{i=1}^r \alpha_i x_i + \varepsilon_k \right]$$

$\vec{u}_k \approx \lambda_1^k \sum_{i=1}^r \alpha_i \vec{x}_i$ , 即 $u_k$ 可以近似的作为**属于 $\lambda_1$ 的特征向量**.

**A的最大特征值是r重时, 幂方法仍然有效**



## 注记:

1. 该方法的本质是  $u_k = A^k u_0$ , 因此得名**幂方法**;
2. A有n个线性无关的特征向量时, 幂方法有效
3. 当矩阵没有n个线性无关的特征向量时, 幂法仍然有效, 只是收敛速度很慢, 应换其他方法.
4. 为防止  $u_k$  过大或过小, 我们在每一步迭代中, 对迭代向量**规范化**, 使得其范数等于1.

设有一非零向量  $v$ , 将其规范化得到向量

$$y = \frac{u}{\|u\|},$$



$$y_0 = u_0,$$

$$\left\{ \begin{array}{l} u_1 = Ay_0 = Au_0, \longrightarrow y_1 = \frac{u_1}{\|u_1\|} = \frac{Au_0}{\|Au_0\|}, \\ u_2 = Ay_1 = \frac{A^2 u_0}{\|Au_0\|}, \longrightarrow y_2 = \frac{u_2}{\|u_2\|} = \frac{A^2 u_0}{\|A^2 u_0\|}, \\ \dots\dots\dots \dots\dots\dots \\ u_k = Ay_{k-1} = \frac{A^k u_0}{\|A^{k-1} u_0\|}, \longrightarrow y_k = \frac{u_k}{\|u_k\|} = \frac{A^k u_0}{\|A^k u_0\|}. \end{array} \right.$$



一般情况下迭代公式  $\begin{cases} \text{选取非零向量 } u_0, \\ u_k = Au_{k-1}, (k=1,2,\cdots) \end{cases}$

实际使用的迭代公式为：

$$u_k = \frac{Au_{k-1}}{\|u_{k-1}\|} = \frac{A^2u_{k-2}}{\|Au_{k-2}\|} = \cdots = \frac{A^k u_0}{\|A^{k-1}u_0\|}.$$

$$\begin{cases} \text{选取非零向量 } u_0 \\ y_{k-1} = \frac{u_{k-1}}{\|u_{k-1}\|} \\ u_k = Ay_{k-1}, (k \geq 1) \end{cases}$$

$\forall \vec{u}_0 \neq \vec{0}, \vec{u}_0 = \alpha_1 x_1 + \alpha_2 x_2 + \cdots + \alpha_n x_n$ , 假设  $\alpha_1 \neq 0$ .

$$y_k = \frac{u_k}{\|u_k\|} = \frac{A^k u_0}{\|A^k u_0\|}$$



**证明：** 设  $u_0 = \alpha_1 x_1 + \alpha_2 x_2 + \cdots + \alpha_n x_n$ ,

$$u_k = Au_{k-1} = A^2 u_{k-2} = \cdots = A^k u_0 = \alpha_1 A^k x_1 + \alpha_2 A^k x_2 + \cdots + \alpha_n A^k x_n$$

$$= \alpha_1 \lambda_1^k x_1 + \alpha_2 \lambda_2^k x_2 + \cdots + \alpha_n \lambda_n^k x_n$$

$$= \lambda_1^k \left[ \alpha_1 x_1 + \alpha_2 \left( \frac{\lambda_2^k}{\lambda_1^k} \right) x_2 + \cdots + \alpha_n \left( \frac{\lambda_n^k}{\lambda_1^k} \right) x_n \right]$$

$$\| A^k u_0 \| = |\lambda_1^k| \left[ \left\| \alpha_1 x_1 + \alpha_2 \left( \frac{\lambda_2^k}{\lambda_1^k} \right) x_2 + \cdots + \alpha_n \left( \frac{\lambda_n^k}{\lambda_1^k} \right) x_n \right\| \right]$$



一般情况下迭代公式  $\begin{cases} \text{选取非零向量 } u_0, \\ u_k = Au_{k-1}, (k=1, 2, \dots) \end{cases}$

实际使用的迭代公式为：

$$u_k = \frac{Au_{k-1}}{\|u_{k-1}\|} = \frac{A^2u_{k-2}}{\|Au_{k-1}\|} = \dots = \frac{A^k u_0}{\|A^{k-1}u_0\|}.$$

$$\begin{cases} \text{选取非零向量 } u_0 \\ y_{k-1} = \frac{u_{k-1}}{\|u_{k-1}\|} \\ u_k = Ay_{k-1}, (k \geq 1) \end{cases}$$

$\forall \vec{u}_0 \neq \vec{0}, \vec{u}_0 = \alpha_1 x_1 + \alpha_2 x_2 + \dots + \alpha_n x_n$ , 假设  $\alpha_1 \neq 0$ .

$$y_k = \frac{u_k}{\|u_k\|} = \frac{A^k u_0}{\|A^k u_0\|} = \left( \frac{\lambda_1}{|\lambda_1|} \right)^k \frac{\alpha_1 x_1 + \alpha_2 \left( \frac{\lambda_2^k}{\lambda_1^k} \right) x_2 + \dots + \alpha_n \left( \frac{\lambda_n^k}{\lambda_1^k} \right) x_n}{\left\| \alpha_1 x_1 + \alpha_2 \left( \frac{\lambda_2^k}{\lambda_1^k} \right) x_2 + \dots + \alpha_n \left( \frac{\lambda_n^k}{\lambda_1^k} \right) x_n \right\|}$$



$$y_k = \left( \frac{\lambda_1}{|\lambda_1|} \right)^k \frac{\alpha_1 x_1 + \alpha_2 \left( \frac{\lambda_2^k}{\lambda_1^k} \right) x_2 + \cdots + \alpha_n \left( \frac{\lambda_n^k}{\lambda_1^k} \right) x_n}{\left\| \alpha_1 x_1 + \alpha_2 \left( \frac{\lambda_2^k}{\lambda_1^k} \right) x_2 + \cdots + \alpha_n \left( \frac{\lambda_n^k}{\lambda_1^k} \right) x_n \right\|}$$

如果  $\lambda_1 > 0, \Rightarrow y_k \xrightarrow{k \rightarrow \infty} \frac{\alpha_1 x_1}{\| \alpha_1 x_1 \|}$ , 如果  $\lambda_1 < 0, \Rightarrow y_k \approx (-1)^k \frac{\alpha_1 x_1}{\| \alpha_1 x_1 \|}$ ,

当  $k \rightarrow +\infty$  时,

$$A y_k \sim A \left[ (\pm 1)^k \frac{\alpha_1 x_1}{\| \alpha_1 x_1 \|} \right] = (\pm 1)^k \frac{\alpha_1 A x_1}{\| \alpha_1 x_1 \|} = (-1)^k \frac{\lambda_1 \alpha_1 x_1}{\| \alpha_1 x_1 \|} = \lambda_1 y_k.$$

这说明  $y_k$  可以近似地作为  $A$  的属于特征值  $\lambda_1$  对应的特征向量。



# 不同范数选取下的特征值的计算

## 1. 取范数为2-范数时

$$y_k \approx (\pm 1)^k \frac{\alpha_1 x_1}{\| \alpha_1 x_1 \|_2},$$

令  $\beta_k = y_{k-1}^T u_k$ , 由于  $u_k = Ay_{k-1} \sim \lambda_1 y_{k-1}$

$$\beta_k = y_{k-1}^T Ay_{k-1} \sim y_{k-1}^T \lambda_1 y_{k-1}, \quad k \rightarrow \infty.$$

$$\lim_{k \rightarrow \infty} \beta_k = \lim_{k \rightarrow \infty} y_{k-1}^T \lambda_1 y_{k-1} = \lambda_1 \|y_{k-1}\|_2^2 = \lambda_1$$

对应的迭代公式

$$\begin{cases} \forall \mathbf{0} \neq u_0 \in R^n \\ \eta_{k-1} = \sqrt{u_{k-1}^T u_{k-1}} \\ y_{k-1} = u_{k-1} / \eta_{k-1} \\ u_k = Ay_{k-1} \\ \beta_k = y_{k-1}^T u_k, \end{cases} \quad (k = 1, 2, \dots)$$

$$\frac{|\beta_k - \beta_{k-1}|}{|\beta_k|} \leq \varepsilon \text{ 时终止程序,}$$

当前的  $\beta_k$  与  $y_{k-1}$  分别为  $\lambda_1$  和与它对应的特征向量.

编制程序容易, 迭代一次所需时间较短



## 2. 取范数为 $\infty$ -范数时

假设 $u_{k-1}$ 的第 $r$ 个分量为模最大的分量,令 $\beta_k = \frac{\vec{e}_r^T u_k}{\vec{e}_r^T y_{k-1}}, = \text{sign}(h_r^{(k-1)})h_r^{(k)}$

由于 $u_k = Ay_{k-1} \sim \lambda_1 y_{k-1}$   $\beta_k = \frac{\vec{e}_r^T u_k}{\vec{e}_r^T y_{k-1}} \sim \frac{\vec{e}_r^T \lambda_1 y_{k-1}}{\vec{e}_r^T y_{k-1}} = \lambda_1, \Leftrightarrow \lim_{k \rightarrow \infty} \beta_k = \lambda_1.$

对应的迭代公式

$$\begin{cases} \text{选取非零向量 } u_0 = (h_0^{(1)}, h_0^{(2)}, \dots, h_0^{(n)})^T \\ y_{k-1} = \frac{u_{k-1}}{\|u_{k-1}\|_\infty}, k = 1, 2, \dots \\ u_k = Ay_{k-1} = (h_1^{(k)}, \dots, h_n^{(k)})^T \quad |h_r^{(k-1)}| = \|u_{k-1}\|_\infty \\ \beta_k = \text{sign}(h_r^{(k-1)})h_r^{(k)}, k = 1, 2, \dots \end{cases}$$

$\frac{|\beta_k - \beta_{k-1}|}{|\beta_k|} \leq \varepsilon$ 时终止程序,当前的 $\beta_k$ 与 $y_{k-1}$ 分别为 $\lambda_1$ 和与它对应的特征向量.

选主元, 所需时间较长, 但舍入误差小.



理解:  $\beta_k = \frac{\vec{e}_r^T u_k}{\vec{e}_r^T y_{k-1}} = \text{sign}(h_r^{(k-1)}) h_r^{(k)}$

$$u_{k-1} = (1, -3, 2, 6)^T, \|h_4^{(k-1)}\| = \|u_{k-1}\|_\infty, h_4^{(k-1)} = 6,$$

$$y_{k-1} = \frac{u_{k-1}}{\|u_{k-1}\|_\infty} = \left(\frac{1}{6}, -\frac{1}{2}, \frac{1}{3}, 1\right)^T, \quad \vec{e}_4 = (0, 0, 0, 1),$$

$$\text{设 } u_k = (0, -7, 1, 3) = Ay_{k-1} = (h_1^{(k)}, h_2^{(k)}, h_3^{(k)}, h_4^{(k)}),$$

$$\beta_k = \frac{\vec{e}_4^T u_k}{\vec{e}_4^T y_{k-1}} = h_4^{(k)} = 3 = \text{sign}(h_4^{(k-1)}) h_4^{(k)}.$$



**例2:** 用幂法求矩阵  $A = \begin{bmatrix} 2 & -1 & 0 \\ 0 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$  的按模最大的特征值

和相应的特征向量。取  $u_0 = (0, 0, 1)$ ,  $\frac{|\beta_k - \beta_{k-1}|}{|\beta_k|} < \frac{1}{2} \times 10^{-3}$ .

**解:**  $u_0 = (0, 0, 1)^T$ ,  $|h_3^{(0)}| = \|u_0\|_\infty = 1$ ,  $y_0 = (0, 0, 1)^T$ ,  $\text{sign}(h_3^{(0)}) = 1$ ,

$$u_1 = Ay_0 = (0, -1, 2)^T, h_3^{(1)} = 2, \quad y_1 = \frac{u_1}{|h_3^{(1)}|} = (0, -\frac{1}{2}, 1)^T,$$

$$\beta_1 = \text{sgn}(h_3^{(0)})h_3^{(1)} = 2, \quad \text{sign}(h_3^{(1)}) = 1,$$

$$u_2 = Ay_1 = (0.5, -2, 2.5)^T, h_3^{(2)} = 2.5, \quad y_2 = \frac{u_2}{|h_3^{(2)}|} = (0.2, -0.8, 1)^T,$$

$$\beta_2 = \text{sgn}(h_3^{(1)})h_3^{(2)} = 2.5, \quad \text{sign}(h_3^{(2)}) = 1, \quad \dots\dots$$



$$u_8 = Ay_7 = (2.7650948, -2.9981848, 2.9990924)^T, h_3^{(8)} = 2.9990924,$$

$$y_8 = \frac{u_8}{|h_3^{(8)}|} = (0.9219772, -0.9996973, 1)^T, \beta_8 = \text{sign}(h_3^{(7)})h_3^{(8)} = 2.9990924,$$

$$\text{sign}(h_3^{(7)})=1,$$

$$u_9 = Ay_8 = (2.8436517, -2.9993946, 2.9996973)^T, h_3^{(9)} = 2.9996973,$$

$$\text{sign}(h_3^{(8)})=1, \quad \beta_9 = \text{sign}(h_3^{(8)})h_3^{(9)} = 2.9996973,$$



k	$v_k$			$u_k$			$\beta_k$
0	0	0	1	0	0	1	
1	0	-1	2	0	0.5	1	2
2	0.5	-2	2.5	0.2	-0.8	1	2.5
.....	.....	.....	.....	.....	.....	.....	.....
8	2.7650948	-2.9981848	2.9990924	0.9219772	-0.9996973	1	2.9990924
9	2.8436517	-2.9993946	2.9996973				2.9996973

由于  $\frac{|\beta_9 - \beta_8|}{|\beta_9|} = \frac{2.9996973 - 2.9990924}{2.9996973} = \frac{0.0006049}{2.9996973} \approx 0.0002017 < \frac{1}{2} \times 10^{-3},$

所以  $\lambda_1 \approx \beta_9 = 2.9996973,$

相应的特征向量为  $x_1 \approx u_8 = \frac{v_8}{|h_3^{(8)}|} = (0.9219772, -0.9996973, 1)^T.$



### 例3：用幂法求矩阵

$$A = \begin{bmatrix} 6 & -12 & 6 \\ -21 & -3 & 24 \\ -12 & -12 & 51 \end{bmatrix}$$

按模最大的特征值  $\lambda_1$  和属于  $\lambda_1$  的特征向量,要求  $|\beta_k - \beta_{k-1}| / |\beta_k| \leq 0.0001$

书本3.1节例1，自学看懂.







北京航空航天大学  
BEIHANG UNIVERSITY

# 数值分析

主讲教师：贺慧霞

北京航空航天大学数学科学学院



# 第三章 矩阵特征值与特征向量的算法

## 3.1 幂法与反幂法



**幂法**是一种计算矩阵按模最大的特征值与其对应的特征向量的迭代方法.

适合于大型稀疏矩阵

### 反幂法

- 1.可以计算矩阵按模最小的特征值与其对应的特征向量;
- 2.求一个给定近似特征值对应的特征向量.



## 二、反幂法

**问题 1:** 假设实矩阵  $A$  具有  $n$  个线性无关的特征向量  $x_1, x_2, \dots, x_n$ ; 相应的特征值  $\lambda_1, \lambda_2, \dots, \lambda_n$ , 已知矩阵的按模最小的特征值  $\lambda_n$  为实数, 且满足

$$|\lambda_1| \geq |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_{n-1}| > |\lambda_n|$$

讨论求  $\lambda_n$  及其对应特征向量的方法.

设  $A$  非奇异, 则  $\lambda_i \neq 0$ , 且  $\frac{1}{\lambda_i}$  是  $A^{-1}$  的特征值, 即  $A^{-1} x_i = \frac{1}{\lambda_i} x_i$

$A^{-1}$  的特征值满足  $|\frac{1}{\lambda_n}| > |\frac{1}{\lambda_{n-1}}| \geq \dots \geq |\frac{1}{\lambda_2}| \geq |\frac{1}{\lambda_1}|$



$A^{-1}$ 的特征值满足  $|\frac{1}{\lambda_n}| > |\frac{1}{\lambda_{n-1}}| \geq \dots \geq |\frac{1}{\lambda_2}| \geq |\frac{1}{\lambda_1}|$

对于  $A^{-1}$  应用幂方法  $\left\{ \begin{array}{l} y_{k-1} = \frac{u_{k-1}}{\|u_{k-1}\|} \\ u_k = A^{-1} y_{k-1} \end{array} \right. \rightarrow \left\{ \begin{array}{l} y_{k-1} = \frac{u_{k-1}}{\|u_{k-1}\|} \\ Au_k = y_{k-1} \end{array} \right.$

可计算出  $A^{-1}$  的按模最大的特征值, 其倒数恰好为  $A$  的按模最小的特征值



**定理1** 假设实矩阵 $A$ 具有 $n$ 个线性无关的特征向量 $x_1, x_2, \dots, x_n$ , 相应的特征值 $\lambda_1, \lambda_2, \dots, \lambda_n$ 满足

$$|\lambda_1| \geq |\lambda_2| \geq \dots \geq |\lambda_{n-1}| > |\lambda_n| > 0,$$

则对任意的非零初始向量 $u_0 = \sum_{i=1}^n \alpha_i x_i$  (至少有一个 $\alpha_i \neq 0$ ), 由反幂法迭代公式构造的向量序列 $\{y_k\}, \{u_k\}$ 满足

$$(1) \lim_{k \rightarrow \infty} y_k = \frac{x_n}{\|x_n\|}, \quad (2) \lim_{k \rightarrow \infty} \|u_k\| = \frac{1}{\lambda_n}.$$

$$\begin{cases} u_0 \neq 0 \\ y_{k-1} = \frac{u_{k-1}}{\|u_{k-1}\|} \\ Au_k = y_{k-1} \end{cases}$$



## 1. 取范数为 $\infty$ -范数时

对应的迭代公式

$$\begin{cases} \text{选取非零向量 } \mathbf{u}_0 \\ \mathbf{y}_{k-1} = \frac{\mathbf{u}_{k-1}}{\|\mathbf{u}_{k-1}\|_\infty}, k = 1, 2, \dots \\ A\mathbf{u}_k = \mathbf{y}_{k-1} \\ \beta_k = \text{sign}(\mathbf{h}_r^{(k-1)})\mathbf{h}_r^{(k)}, k = 1, 2, \dots \quad \|\mathbf{h}_r^{(k-1)}\| = \|\mathbf{u}_{k-1}\|_\infty \end{cases}$$

$$\frac{|\beta_k - \beta_{k-1}|}{|\beta_k|} \leq \varepsilon \text{ 时终止程序.}$$

$$\lambda_n \approx \frac{1}{\beta_k}, \mathbf{y}_{k-1} \text{ 可近似作为矩阵 } A \text{ 的属于 } \lambda_n \text{ 的特征向量.}$$



## 2. 取范数为2-范数时的迭代公式

对应的迭代公式

$$\left\{ \begin{array}{l} \forall \mathbf{0} \neq \mathbf{u}_0 \in R^n \\ \eta_{k-1} = \sqrt{\mathbf{u}_{k-1}^T \mathbf{u}_{k-1}} \\ \mathbf{y}_{k-1} = \mathbf{u}_{k-1} / \eta_{k-1} \\ A\mathbf{u}_k = \mathbf{y}_{k-1} \\ \beta_k = \mathbf{y}_{k-1}^T \mathbf{u}_k \\ (k = 1, 2, \dots) \end{array} \right.$$

$$\frac{|\beta_k - \beta_{k-1}|}{|\beta_k|} \leq \varepsilon \text{ 时终止程序.}$$

$$\left\{ \begin{array}{l} \mathbf{y}_{k-1} = \frac{\mathbf{u}_{k-1}}{\|\mathbf{u}_{k-1}\|} \\ A\mathbf{u}_k = \mathbf{y}_{k-1} \end{array} \right.$$

$$r = \frac{|\lambda_n|}{|\lambda_{n-1}|} \text{ 越小, 收敛速度越快.}$$

$r \rightarrow 1$ , 收敛可能很慢.

$$\lambda_n \approx \frac{1}{\beta_k}, \mathbf{y}_{k-1} \text{ 可近似作为矩阵 } A \text{ 的属于 } \lambda_n \text{ 的特征向量.}$$





## 反幂法的解题步骤:

1.对 $A$ 进行三角分解 $A = LU$ , (或者 $PA = LU$ ,  $P$ 是置换矩阵) ,

2.取非零向量 $v_0$ , 计算 $\|v_0\|$ , 得 $u_0 = \frac{v_0}{\|v_0\|}$ ,

3.  $LUv_1 = u_0, \Leftrightarrow \begin{cases} Ly_1 = u_0 \\ Uv_1 = y_1 \end{cases} \Rightarrow v_1 \Rightarrow u_1 = \frac{v_1}{\|v_1\|},$

4.  $LUv_2 = u_1, \Leftrightarrow \begin{cases} Ly_2 = u_1 \\ Uv_2 = y_2 \end{cases} \Rightarrow v_2 \Rightarrow u_2 = \frac{v_2}{\|v_2\|}, \dots\dots$

5.  $LUv_k = u_{k-1}, \Leftrightarrow \begin{cases} Ly_k = u_{k-1} \\ Uv_k = y_k \end{cases} \Rightarrow v_k \Rightarrow u_k = \frac{v_k}{\|v_k\|},$



【例】用反幂法求  $A = \begin{pmatrix} 2 & 1 & 0 \\ 1 & 3 & 1 \\ 0 & 1 & 4 \end{pmatrix}$  的按模最小的特征值及对应的特征向量.  
LU分解计算  $u_k, y_k, \beta_k$

【解】把  $A$  做三角分解，得

$$L = \begin{pmatrix} 1 & 0 & 0 \\ 0.5 & 1 & 0 \\ 0 & 0.4 & 1 \end{pmatrix}, U = \begin{pmatrix} 2 & 1 & 0 \\ 0 & 2.5 & 1 \\ 0 & 0 & 3.6 \end{pmatrix}, \quad \text{迭代公式}$$

$$u_0 = (0, 0, 1)^T \quad \text{则 } y_0 = (0, 0, 1)^T$$

$$Au_1 = LUu_1 = y_0 = (0, 0, 1)^T \quad \text{记 } w_1 = Uu_1 = (w_{11}, w_{12}, w_{13})^T,$$

$$Lw_1 = \begin{pmatrix} 1 & 0 & 0 \\ 0.5 & 1 & 0 \\ 0 & 0.4 & 1 \end{pmatrix} \begin{pmatrix} w_{11} \\ w_{12} \\ w_{13} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}, \quad \Rightarrow \begin{pmatrix} w_{11} \\ w_{12} \\ w_{13} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix},$$

$$\begin{cases} \forall 0 \neq u_0 \in R^n \\ \eta_{k-1} = \sqrt{u_{k-1}^T u_{k-1}} \\ y_{k-1} = u_{k-1} / \eta_{k-1} \\ Au_k = y_{k-1} \\ \beta_k = y_{k-1}^T u_k, (k = 1, 2, \dots) \end{cases}$$



$$Uu_1 = \begin{pmatrix} 2 & 1 & 0 \\ 0 & 2.5 & 1 \\ 0 & 0 & 3.6 \end{pmatrix} \begin{pmatrix} u_{11} \\ u_{12} \\ u_{13} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}, \Rightarrow \begin{pmatrix} u_{11} \\ u_{12} \\ u_{13} \end{pmatrix} = \begin{pmatrix} 1/18 \\ -1/9 \\ 5/18 \end{pmatrix}, \beta_1 = y_0^T u_1 = \frac{5}{18}.$$

$$y_1 = \frac{u_1}{\|u_1\|_2} = \frac{(1, -2, 5)^T}{\sqrt{30}}$$

$$Au_2 = LUu_2 = y_1,$$

$$\text{记 } w_2 = Uu_2 = (w_{21}, w_{22}, w_{23})^T,$$

迭代公式

$$\begin{cases} \forall 0 \neq u_0 \in R^n \\ \eta_{k-1} = \sqrt{u_{k-1}^T u_{k-1}} \\ y_{k-1} = u_{k-1} / \eta_{k-1} \\ Au_k = y_{k-1} \\ \beta_k = y_{k-1}^T u_k, (k = 1, 2, \dots) \end{cases}$$

$$Lw_2 = \begin{pmatrix} 1 & 0 & 0 \\ 0.5 & 1 & 0 \\ 0 & 0.5 & 1 \end{pmatrix} \begin{pmatrix} w_{21} \\ w_{22} \\ w_{23} \end{pmatrix} = \frac{1}{\sqrt{30}} \begin{pmatrix} 1 \\ -2 \\ 5 \end{pmatrix}, \Rightarrow \begin{pmatrix} w_{21} \\ w_{22} \\ w_{23} \end{pmatrix} = \dots$$



## 例 2 用反幂法求矩阵

$$A = \begin{bmatrix} 6 & -12 & 6 \\ -21 & -3 & 24 \\ -12 & -12 & 51 \end{bmatrix}$$

的按模最小的特征值和相应的特征向量,要求  $|\beta_k^{-1} - \beta_{k-1}^{-1}| / |\beta_k^{-1}| \leq 0.005$ 。

对应的迭代公式

$$\begin{cases} \forall \mathbf{0} \neq \mathbf{u}_0 \in R^n \\ \eta_{k-1} = \sqrt{\mathbf{u}_{k-1}^T \mathbf{u}_{k-1}} \\ \mathbf{y}_{k-1} = \mathbf{u}_{k-1} / \eta_{k-1} \\ A\mathbf{u}_k = \mathbf{y}_{k-1} \\ \beta_k = \mathbf{y}_{k-1}^T \mathbf{u}_k \\ (k = 1, 2, \dots) \end{cases}$$

$$\mathbf{u}_0 = (1, 1, 1)^T$$

$$\mathbf{y}_0 = \frac{(1, 1, 1)^T}{\sqrt{3}}$$

LU分解计算  $\mathbf{u}_k, \mathbf{y}_k, \beta_k$



表 3-2 例 2 计算结果

$k$	$u_k^T$			$y_k^T$			$\beta_k$
0	1.000 0	1.000 0	1.000 0	0.577 4	0.577 4	0.577 4	
1	-0.032 1	-0.070 6	-0.012 8	-0.408 2	-0.898 1	-0.163 3	-0.066 7
2	0.068 0	0.084 4	0.008 5	0.627 8	0.778 4	0.078 1	-0.104 9
3	-0.066 4	-0.104 9	-0.038 8	-0.510 5	-0.806 5	-0.298 1	-0.126 4
4	0.058 2	0.085 6	0.028 0	0.542 4	0.798 5	0.261 0	-0.107 1
5	-0.059 5	-0.090 0	-0.030 1	-0.531 4	-0.803 5	-0.268 4	-0.112 0
6	0.059 4	0.088 8	0.029 6	0.535 9	0.800 9	0.267 1	-0.110 9
7	-0.059 4	-0.089 2	-0.029 7				-0.111 2

$\beta_7$  已满足精度要求。所以,  $A$  的按模最小的特征值为  $\lambda_3 \approx \frac{1}{\beta_7} = -8.992\ 8$ , 相应的特征向量为  $x_3 \approx (0.535\ 9, 0.800\ 9, 0.267\ 1)^T$ 。



## 二、带原点平移的反幂法---对 $(A-pI)^{-1}$ 用幂法

**定理1** 设 $\lambda$ 是矩阵 $A \in R^{n \times n}$ 的特征值， $x$ 是对应的非零特征向量，则

(1)  $c\lambda$ 是 $cA$ 的特征值 (常数 $c \neq 0$ );

(2)  $\lambda - p$ 为 $A - pI$ 的特征值, 即  $(A - pI)x = (\lambda - p)x$ ;

(3)  $\lambda^k$ 是 $A^k$ 的特征值, 即  $A^k x = \lambda^k x$ ;

(4) 设 $A$ 非奇异, 则  $\lambda \neq 0$  且  $\frac{1}{\lambda}$  为 $A^{-1}$ 的特征值, 即  $A^{-1}x = \frac{1}{\lambda}x$ .

$$\left\{ \begin{array}{l} \forall 0 \neq u_0 \\ y_{k-1} = \frac{u_{k-1}}{\|u_{k-1}\|} \\ u_k = (A - pI)^{-1} y_{k-1} \end{array} \right. \quad \longrightarrow \quad \left\{ \begin{array}{l} \forall 0 \neq u \\ y_{k-1} = \frac{u_{k-1}}{\|u_{k-1}\|} \\ (A - pI)u_k = y_{k-1} \end{array} \right.$$



**定理2** 假设实矩阵 $A$ 具有 $n$ 个线性无关的特征向量 $x_1, x_2, \dots, x_n$ , 相应的特征值 $\lambda_1, \lambda_2, \dots, \lambda_n$ , 而 $p$ 为 $\lambda_j$ 的近似值,  $(A - pI)^{-1}$ 存在, 且

$$|\lambda_j - p| \ll |\lambda_i - p|, \quad i \neq j,$$

对任意的非零初始向量 $u_0 = \sum_{i=1}^n \alpha_i x_i$  (至少存在一个 $\alpha_i \neq 0$ ), 由反幂法

迭代公式构造的向量序列 $\{u_k\}, \{y_k\}$

$$\begin{cases} y_{k-1} = \frac{u_{k-1}}{\|u_{k-1}\|} \\ Au_k = y_{k-1} \end{cases}$$

2-范数时的迭代公式

$$\begin{cases} \forall u_0 \in R^n \\ \eta_{k-1} = \sqrt{u_{k-1}^T u_{k-1}} \\ y_{k-1} = u_{k-1} / \eta_{k-1} \\ (A - pI)u_k = y_{k-1} \\ \beta_k = y_{k-1}^T u_k \\ (k = 1, 2, \dots) \end{cases}$$



## 取范数为 $\infty$ -范数时

对应的迭代公式

$$\left\{ \begin{array}{l} \text{选取非零向量 } u_0 \\ y_{k-1} = \frac{u_{k-1}}{\|u_{k-1}\|_{\infty}}, k = 1, 2, \dots \\ (A - pI)u_k = y_{k-1} \\ \beta_k = \text{sign}(h_r^{(k-1)})h_r^{(k)}, k = 1, 2, \dots \quad |h_r^{(k-1)}| = \|u_{k-1}\|_{\infty} \end{array} \right.$$

收敛速度由  $r = \frac{|\lambda_j - p|}{\min_{i \neq j} |\lambda_i - p|}$  确定.  $\frac{|\beta_k - \beta_{k-1}|}{|\beta_k|} \leq \varepsilon$  时终止程序.

$\lambda_n \approx p + \frac{1}{\|u_k\|}$ ,  $y_{k-1}$  可近似作为矩阵A的属于 $\lambda_n$ 的特征向量.





给定 $A$ 的特征值 $\lambda_j$ 的一个近似值 $p$ ,求 $p$ 对应的特征向量 $x_j$ 的步骤:

1.对 $A$ 进行三角分解 $A - pI = LU$ , (或者 $P(A - pI) = LU$ ,  $P$ 是置换矩阵) ,

2.取非零向量 $v_0 = (1, 1, \dots, 1)^T$ ,

$$3. \quad LUv_1 = v_0 = (1, 1, \dots, 1)^T \Leftrightarrow \begin{cases} Ly_1 = v_0 \\ Uv_1 = y_1 \end{cases} \Rightarrow v_1 \Rightarrow u_1 = \frac{v_1}{\|v_1\|},$$

$$4. \quad LUv_2 = u_1, \Leftrightarrow \begin{cases} Ly_2 = u_1 \\ Uv_2 = y_2 \end{cases} \Rightarrow v_2 \Rightarrow u_2 = \frac{v_2}{\|v_2\|}, \dots\dots$$

$$5. \quad \lambda_k \approx p + \frac{1}{\|v_k\|}, \text{对应的特征向量为 } u_k = \frac{v_k}{\|v_k\|}.$$



【例】用反幂法求  $A = \begin{pmatrix} 2 & 1 & 0 \\ 1 & 3 & 1 \\ 0 & 1 & 4 \end{pmatrix}$  的对应于特征值  $p = 1.2679$

(精确特征值为  $\lambda_3 = 3 - \sqrt{3}$ ) 的特征向量 (计算两步即可)。

【解】由选主元的三角分解将  $A - pI$  分解为  $(A - pI) = LU$ , 其中



$$L = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0.7321 & -0.26807 & 1 \end{pmatrix}, U = \begin{pmatrix} 1 & 1.7321 & 1 \\ 0 & 1 & 2.7321 \\ 0 & 0 & 0.29405 \times 10^{-3} \end{pmatrix}, P = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{pmatrix},$$

$$(1) \quad v_0 = (1, 1, 1)^T, \quad (A - pI)v_1 = LUv_1 = v_0, \quad \text{令} \begin{cases} Ly_1 = v_0 \\ Uy_1 = y_1 \end{cases},$$



$$A - pI = \begin{pmatrix} 0.7321 & 1 & 0 \\ 1 & 1.7321 & 1 \\ 0 & 1 & 2.7321 \end{pmatrix} \xrightarrow{r_1 \leftrightarrow r_2} \begin{pmatrix} 1 & 1.7321 & 1 \\ 0.7321 & 1 & 0 \\ 0 & 1 & 2.7321 \end{pmatrix}$$

$$\rightarrow \begin{pmatrix} 1 & 1.7321 & 1 \\ 0.7321 & 1 - 0.7321 * 1.7321 & 0 \\ 0 & 1 & 2.7321 \end{pmatrix} = \begin{pmatrix} 1 & 1.7321 & 1 \\ 0.7321 & -0.26807 & 0 \\ 0 & 1 & 2.7321 \end{pmatrix}$$

$$\xrightarrow{r_2 \leftrightarrow r_3} \begin{pmatrix} 1 & 1.7321 & 1 \\ 0 & 1 & 2.7321 \\ 0.7321 & -0.26807 & 0 \end{pmatrix} \longrightarrow \begin{pmatrix} 1 & 1.7321 & 1 \\ 0 & 1 & 2.7321 \\ 0.7321 & -0.26807 & 0 - 0.7321 * 1 \\ & & + 0.26807 * 2.7321 \end{pmatrix}$$

【例】用反幂法求  $A = \begin{pmatrix} 2 & 1 & 0 \\ 1 & 3 & 1 \\ 0 & 1 & 4 \end{pmatrix}$  的对应于特征值  $p = 1.2679$

(精确特征值为  $\lambda_3 = 3 - \sqrt{3}$ ) 的特征向量 (计算两步即可)。

【解】由选主元的三角分解将  $A - pI$  分解为  $(A - pI) = LU$ , 其中



$$L = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0.7321 & -0.26807 & 1 \end{pmatrix}, U = \begin{pmatrix} 1 & 1.7321 & 1 \\ 0 & 1 & 2.7321 \\ 0 & 0 & 0.29405 \times 10^{-3} \end{pmatrix}, P = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{pmatrix},$$

$$(1) \quad v_0 = (1, 1, 1)^T, \quad (A - pI)v_1 = LUv_1 = v_0, \quad \text{令} \begin{cases} Uv_1 = y_1 \\ Ly_1 = v_0 \end{cases},$$



(1)  $\mathbf{v}_0 = (1, 1, 1)^T$ , 解方程组  $(A - pI)\mathbf{v}_1 = LU\mathbf{v}_1 = \mathbf{v}_0$ ,

$$\mathbf{y}_1 = (1, 1, 0.53597)^T,$$

$$\mathbf{v}_1 = (6802.1, -4978.8, 1822.7)^T,$$

$$\mathbf{u}_1 = \frac{\mathbf{v}_1}{\|\mathbf{v}_1\|_\infty} = (1, -0.73195, 0.26796)^T,$$

(2) 解方程组  $(A - pI)\mathbf{v}_2 = LU\mathbf{v}_2 = P\mathbf{u}_1$ , 令 
$$\begin{cases} L\mathbf{y}_2 = P\mathbf{u}_1 = (-0.73195, 0.26796, 1)^T, \\ U\mathbf{v}_2 = \mathbf{y}_2 \end{cases}$$

$$\mathbf{y}_2 = (-0.73195, 0.26796, 1.60769)^T, \mathbf{v}_2 = (20404.6, -14937.2, 5467.4)^T,$$

$$L = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0.7321 & -0.26807 & 1 \end{pmatrix}, U = \begin{pmatrix} 1 & 1.7321 & 1 \\ 0 & 1 & 2.7321 \\ 0 & 0 & 0.29405 \times 10^{-3} \end{pmatrix}, P = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{pmatrix}$$

$$\mathbf{v}_2 = (20404.6, -14937.2, 5467.4)^T,$$

$$\mathbf{u}_2 = \frac{\mathbf{v}_2}{\|\mathbf{v}_2\|_\infty} = (1, -0.73205, 0.26795)^T,$$

$\lambda_3=1.2679$ 对应的特征向量是

$$\mathbf{x}_3 = (1, 1 - \sqrt{3}, 2 - \sqrt{3})^T \approx (1, -0.73206, 0.26795)^T,$$

由此看出 $\mathbf{u}_2$ 是 $\mathbf{x}_3$ 的相当好的近似.

$$\text{特征值 } \lambda_3 \approx 1.2679 + \frac{1}{\|\mathbf{v}_2\|} \approx 1.2679\mathbf{4901},$$

$$\lambda_3 \text{ 的真实值 } \lambda_3 = 3 - \sqrt{3} = 1.2679\mathbf{4912}\dots.$$



# 总结

- ❖ 幂法可以用来求矩阵模最大的特征值和特征向量；  
 $A \rightarrow (A^{-1})$  幂方法
- ❖ 反幂法可以用来求矩阵模最小的特征值和特征向量；
- ❖ 当 $|\lambda_1|=|\lambda_2|$ ，但 $\lambda_1=-\lambda_2$ 时，直接幂法失败；  
当 $|\lambda_{n-1}|=|\lambda_n|$ ，但 $\lambda_{n-1}=-\lambda_n$ 时，直接反幂法失败；
- ❖ 当是多重特征值时，幂法和反幂法仍有效。



# 作 业

- ❖ 教材第65页：习题1、3，6，7
- ❖ 课外阅读：《C数值算法》第11章

